Questionário — Treinamento e Avaliação de CNN

Guilherme Grigolin da Mata Brandão — Bacharelado em Sistemas de Informação, IFSP
Base: Intel Image Classification · CNN treinada do zero (TensorFlow/Keras)

1. Você manteve a arquitetura original da CNN ou modificou as camadas? Quais alterações realizou?

Modifiquei. Em relação ao notebook de referência (2 Conv2D de 32 filtros + Flatten, entrada 150×150), usei a arquitetura proposta no enunciado: entrada 128×128×3, três blocos Conv2D 3×3 + ReLU + MaxPooling com 32, 64 e 128 filtros, GlobalAveragePooling, Dense(128) e Dense(6) — 110.534 parâmetros (modelo E0).

Nos experimentos, adicionei um quarto bloco Conv2D(256) (E2) e uma camada Dropout antes da saída (E3/E4). O modelo final (E7) tem **4 blocos (32-64-128-256) + Dropout 0,3**, com 422.086 parâmetros.

2. Quais funções de ativação foram utilizadas nas camadas intermediárias e na camada de saída?

ReLU em todas as camadas convolucionais e na Dense(128) oculta; **softmax** na camada de saída (6 neurônios), que gera a probabilidade de cada classe.

3. Foi utilizada alguma técnica de normalização dos dados? Qual?

Sim. As imagens foram redimensionadas para 128×128 e os pixels **divididos por 255**, ficando no intervalo [0, 1]. Não foi usada BatchNormalization.

4. Você utilizou regularização (L1, L2 ou Dropout)? Qual técnica e quais parâmetros?

Testei **Dropout 0,3** (E3) e **0,5** (E4) entre a Dense(128) e a saída, **L2 = 0,0001** nos kernels das Conv2D e da Dense(128) (E5) e **aumento de dados** (espelhamento horizontal, rotação ±11°, zoom ±10%) (E6). L1 não foi usada. Dropout 0,3 deu o maior ganho (pequeno, +0,011 de F1); Dropout 0,5 e L2 pioraram o resultado. O modelo final usa Dropout 0,3 + aumento de dados.

5. Qual otimizador foi utilizado (Adam, SGD ou outro)? Testou mais de um? Qual apresentou melhor resultado?

Adam em todos os experimentos. Não testei outros otimizadores (extensão opcional no enunciado), para manter as comparações controladas; com Adam o treino foi estável.

6. Qual taxa de aprendizado (learning rate) foi utilizada? Testou outros valores? Qual foi a melhor?

Usei **0,001** e testei **0,0001** (E1). A melhor foi **0,001**: com 0,0001 o aprendizado ficou lento demais e o F1 macro de validação caiu de 0,870 para 0,729 em 30 épocas.

7. Como foi realizado o treinamento: com todo o conjunto, uma amostra por vez ou mini-lotes (mini-batches)? Qual foi o batch size?

Com **mini-lotes de 32 imagens** (350 passos por época), com o treino embaralhado a cada época.

8. Quantas épocas foram utilizadas? Os gráficos de perda e acurácia indicaram overfitting ou underfitting?

Limite de **30 épocas** com EarlyStopping (val_loss, paciência 5, restaurando os melhores pesos). O modelo final rodou 30 épocas, com melhor época na 25ª (treino 0,904 × validação 0,883: pouco overfitting).

O modelo inicial **não teve overfitting** (treino 0,890 × validação 0,869; a melhor época foi a última, a 30ª), e sim leve **underfitting** por falta de épocas. Com lr 0,0001 houve underfitting claro. A rede de 4 blocos sem regularização (E2) começou a ter **overfitting** após a época 18 (perda de validação subindo enquanto a de treino caía).

9. Quais métricas foram utilizadas para avaliar o modelo? Apresente os resultados de validação e teste.

Acurácia, perda (entropia cruzada), **F1 macro** (critério de seleção), precisão/recall/F1 por classe e matriz de confusão. Resultados do modelo final (E7):

	Acurácia	F1 macro	Perda (CE)
Validação	0,883	0,883	0,350
Teste	0,874	0,875	não calculada

F1 por classe no teste: forest 0,970 · sea 0,893 · street 0,888 · buildings 0,844 · glacier 0,835 · mountain 0,820. As maiores confusões foram mountain ↔ glacier e buildings ↔ street.

10. Qual configuração apresentou o melhor desempenho? Justifique com base nos resultados obtidos.

A **E7** (4 blocos + Dropout 0,3 + aumento de dados), com o maior F1 macro de validação (**0,8835**), seguida da E2 (0,8822) e da E3 (0,8804). Ela combina as alterações que melhoraram o E0: mais capacidade e regularização para conter o overfitting que essa capacidade causa. No teste obteve acurácia 0,874 e F1 macro 0,875, próximos da validação. A vantagem sobre a E2 é pequena (0,0013) e custou cerca de 5× mais tempo de treino, principalmente pelo aumento de dados.